

裁判权先于引擎：天气建模自动重整化的可复现计分牌

LSWM/ARM: ScaleBench 公开基准、AIFS 实时对拍体系，与真实数据训练环的诚实教训

LSWM 项目组

<https://github.com/Dolo-borigjin/The-everything>

<https://dolo-borigjin.github.io/The-everything/>

草稿 v0.4 ——2026 年 9 月 28 日

(数字为滚动实测并持续更新；更新机制见 §9。)

摘要

天气 AI 目前没有可复现的公开计分牌：头部分数由各团队按自己的数据、标定与真值口径发布，社区无法重算。我们取相反立场——**裁判权先于引擎**：在宣称更好的引擎之前，先建成让此类宣称可被公开检验的仪器。(i) **ScaleBench** (v2.0)：自动重整化公开基准——给定微观模拟器，机器能否自己发现宏观有效定律，并诚实给出适用边界与误差界。五个任务族对应学习有效理论的五种经典失败模式（教科书复读、网格过拟合、短程拟合、插值冒充定律、混沌未审计伪定律）；当前确定性榜单十七题总分 0.9931，由 `reproduce.py` 端到端可执行仲裁（外部提交须全量复现，容差 ± 0.02 ）。(ii) **AIFS 实时对拍体系**：滚动存档（逐文件 sha256 清单）+ 实测基线表（12–120h, z_{500} /MSL RMSE，全球与珠江口窗），真值口径显式标注（自洽性 vs 独立再分析），run 间散布作为一等数据记录。(iii) **真实数据训练环**（ERA5 驱动的混合核心 + 穿求解器 SPSA）：在线训练协议在两条独立真值通道上均改进其目标；两通道的绝对技巧差经 **实测拒绝尺度假设**后归因于模型动力流形之外的内容，而非不可分辨的波长。(iv) **雨洪链物理化**：ERA5 总降水以物理毫米直驱浅水洪水器官，一次跨案标定，废除逐案归一化。全程一条铁律：每个数字都是实测、每次失败都注册（含我们自身的一次撤回）、每条物理断言都配解析参考测试。基准、榜单 JSON、复现脚本与滚动实测表全部公开。

1 引言：天气 AI 没有计分牌

业务化 AI 天气模型在聚合技巧指标上已可与传统数值预报比肩 [1, 2, 3]。但证据由各家私有口径产出：验证时段不同、真值流不同（自身分析场 vs ERA5 vs 站点观测）、区域加权不同，且不存在任何公开机制可以重算一个已发表的数字。这与 ImageNet 之前的计算机视觉、GLUE 之前的 NLP 如出一辙——而当时起效的药方不是更好的模型，而是 **更好的尺子**。

其下还压着一个更深的缺口。学习型天气模型的宏大承诺是隐式 **重整化**：从可分辨尺度的动力学中推断次格尺度的有效方程。但“学到了次格物理”是一句不可证伪的口号，除非能**考试**这个被学出来的有效理论：在答案已知处它能否恢复已知定律？在一百倍训练视界外它是否稳定？它外推，还是只会内插？它知不知道自己何时不知道？

本文就是这两个缺口的计分牌，以及按它打分的第一个实测赛季。贡献：

1. **ScaleBench v2.0** (§3)：防刷分的自动重整化公开基准，配可执行仲裁脚本；确定性管线十七题总分 0.9931。
2. **AIFS 实时对拍体系** (§4)：字节级溯源滚动档案、12–120h 实测确定性基线（真值口径显式标注）、降水 ETS 通道（首个**有效**独立真值样本 2026-09-24 落地，0.1mm 阈值 ETS 0.712）；ENS 端点已探测并如实报告开放商店无货。
3. **真实数据训练环** (§5)：ERA5 驱动的在线训练在两条真值通道上均成立；较干净通道上的技巧赤字经注册的负结果诊断为动力性的，而非谱性的，并以平衡流形投影审计收口。
4. **物理化雨洪耦合** (§6)：ERA5 tp 以物理毫米直驱洪水器官，一次跨案标定；逐案归一化废除并以守门断言防回退。
5. **纪律即方法** (§7)：全部物理代码配解析参考测试、失败注册而非放宽阈值、我们自己的一条错配实测公开撤回。

2 ARM 架构一页

自动重整化机（ARM）是三循环引擎。**内环**学习模拟器次格倾向的闭合；**中环**学习粗粒化映射（哪些宏观变量存在）；**外环**发现有效定律并以 **ETC 卡**（有效理论卡）发出——卡携带误差界、适用区制与标定记录。两道门约束三循环：G1（spec 冻结权属人类）与 G2（每段物理代码配解析参考测试）。**天气器官**把正压玩具核心耦合到在线训练的修正项（穿求解器 SPSA）；**洪水器官**（Lax–Friedrichs 浅水）把降雨接到淹没与损失。架构本身不是本文主题——**对它的考试**才是。完整设计见项目白皮书 (§4 ARM 架构设计)。

3 ScaleBench：自动重整化基准

3.1 设计：五族考题，五种失败模式

每个任务族针对学习有效理论的一种经典翻车方式，每题的防刷分机制公开：

- **Known-Recovery**——恢复已知定律（KPP 行波速度律 $c = 2\sqrt{rD}$ ），评分扣到系数级：有限差分的前锋系统性滞后按实测计入，“看起来对”不得分。
- **Cross-Resolution**——同一定律必须在三种网格下恢复出同一系数；过拟合网格的”定律”在此必现形。
- **Long-Horizon**——闭合在一百倍训练视界上做漂移审计；未标定闭合在此题必然低分。

- **Discovery**——无教科书答案：系统必须输出带误差界与区制边界的宏观方程（含显式 `theory_gap` 字段），由留出数据（held-out）仲裁。
- **Extrapolation**——校准域之外对拍：插值系统域内满分、域外崩溃。这是”定律 vs 插值”的分水岭。
- **Chaos-Audit**——Lyapunov 指数与吸引子距离进验收门：混沌约束必须是实测，不是假设，否则卡不得进入 decision 级。

3.2 榜单（v2.0，确定性管线，种子固定）

3.3 防刷分是实测出来的，不是宣称出来的

湍流谱发现题最初设为”恢复教科书 k^{-3} ”，实测推翻了考题设计本身（四个区制全部测得 -2.0 至 -2.2 ）——考题被修正为区制有效区间，整个事件记录在考题元数据里。计分牌允许自己错，并把改正公开展示。

3.4 可执行仲裁

`python -m scalebench.reproduce` 全量复跑确定性管线，逐题与公开榜单比对（容差 ± 0.02 ，留给跨平台浮点差），任何不一致非零退出。复现全绿是外部提交的前置条件；宣称的误差界覆盖率按二项 z 检验核验；Discovery 族为最终仲裁题。裁判仪器自身也可被裁判。

4 AIFS 实时对拍体系

4.1 字节级溯源的滚动档案

ECMWF 开放数据的 AIFS 馈送是滚动窗口（实测覆盖约 4 天——纠正了最初”约 30 天”的估计）。因此我们业务化存档：自 2026-09-17 起连续捕获每日两个 run 的关键步（0、12、24、48、72、96、120 h 七档），每文件登记 sha256 与字节数；清单校验器可检出篡改、删除与未登记新增。下文任何结论都可回查到它计算时所用的确切字节。

4.2 实测确定性基线（滚动）

真值口径，明说：验证参考是 AIFS 自身后一日 0h 场——自洽性口径（预报与自身分析帧的一致性），不是独立观测的绝对精度。run 间散布作为一等数据记录（单 run 读数不作判决）。

4.3 降水 ETS 通道：两次定罪，然后首个样本落地

首个独立真值对拍（AIFS 24h 累计降水 vs ERA5 日累计，珠江口窗，多阈值 ETS）于 2026-09-24 落地（run 2026-09-18 00z，对拍 2026-09-18 日累计）：AIFS 窗均值 0.34 mm vs ERA5 0.38 mm；多阈值 $ETS = 0.712$ （0.1 mm）、0.241（1 mm）、1.0（5 mm 与 10 mm——小雨事件，高阈值平凡

饱和，如实标注)。09-25 再落地两个样本 (run 2026-09-18 12z 与 2026-09-19 00z, 对拍 2026-09-19 日累计): 0.1 mm 阈值 $ETS = 0.830 / 0.495$ 、1 mm = $0.176 / 0.143$ 。09-26 第四样本落地 (run 2026-09-20 00z 对拍 2026-09-20 日累计——首个真实雨带案, 窗均值 1.87 vs 1.61 mm): $ETS = 0.691$ (0.1 mm)、0.609 (1 mm)、0.221 (5 mm——高阈值首次非平凡)、1.0 (10 mm)。

饱和阈值定罪。 第五样本 (2026-09-21, 首个强降雨案: AIFS 2.88 vs ERA5 2.60 mm) 在 0.1 mm 阈值 $ETS = 0$ ——不是漏报: AIFS 在窗口每个格点都报雨, 观测事件全部「命中」但随机参照恰好等于命中数 (超出随机的技巧为零); 同一对在 1 mm 阈值 0.642。多阈值设计自诊断: 饱和在表里可见, 不被头条数字掩盖。

首次判决 (2026-09-28)。 run 日池达 $N=5$ ($0.712/0.691/0.495/0.088/0.000$) 后, DRAFT-008 首次试算判决落地——**V-INCONCLUSIVE**: 中位 0.495, 距 V-PASS 阈仅 0.005; 两个湿日 0.1mm 低分把中位拉离干日带。标准的首次启用即产出边界案——这正是判别力标准的本意。两个裁决议题已上桌 (G1-8: 雨日/干日分层; G1-9: 中位数对语义不同零点的稳健性)。

第三起定罪: 时间轴口径。 09-26 通道钓出自家口径错误: ERA5 日文件为**累计结束口径** ($\text{day-}d[d-1\ 23:00, d\ 23:00)$), 00z+24h 预报窗只对齐 **run 日文件** ($\pm 1h$); 看似合法的「有效日配对」实为 23h 偏移。一条此类记录 ($ETS\ 0.238$, 曾被记为真漏雨案) 经逐时精确窗重建定罪 ($ETS\ 0.501$, 与 run 日配对 0.495 一致), 作为 RETRACTED 证据保留; 两处守门已在代码层拒收此类配对, 12z run 一律走分钟级逐时精确窗重建 (首个样本 0.840)。有效样本现为 $N=6$ 双口径 (P1 池 $n=5$ 、P2 池 $n=3$; 首判 V-INCONCLUSIVE 在 §4.3) (run 日 $\pm 1h$: $0.712/0.495/0.691$; 精确窗: 0.840); 判决标准本身为 DRAFT 未冻结 (DRAFT-SPEC-008, 待人类批准)。在样本落地之前, 管线已钓出两个真实缺陷, 均已配守门测试: (i) **千倍单位污染**——AIFS GRIB 的 **tp** 原生单位是 kg m^{-2} (=mm), 而 ERA5 NetCDF 的 **tp** 是米; 两条读取路径现在统一经过显式单位归一, 遇未知单位直接报错而非静默假设; (ii) 我们自己的一次**跨年份错配** (把 2026 年的预报对拍 2018 年的台风日)——产出一个貌似合理却毫无意义的“AIFS 漏掉雨带”结果。该记录已在公开 JSON 中标记 RETRACTED (证据保留), 对拍 runner 现在硬性拒绝预报窗外的验证日。我们把撤回视为方法的一部分, 并把收据留在原地。

4.4 ENS 状态

对 AIFS-ENS 的 CRPS 指标已登记未测: 开放商店五种候选集合产品 URL 模式全部 404 (2026-09-21 探测, 限流退避已遵守), 同日确定性产品 206 正常。集合验证需 ECMWF 账号 (MARS) 或等待官方开放。

5 真实数据训练环：协议成立，赤字是动力性的

天气器官的真实数据链（环 #4-#7）：以 ERA5 派生的涡度真值序列的倾向残差训练点态修正项，再穿求解器做 SPSA 在线微调（多步 rollout 损失）。 13×13 正压核心、6h 步长、异常归一单位。

5.1 协议在两条真值通道上均改进其目标

$\approx_{500}$ 地转涡度 (ζ_g) 与官方 ERA5 涡度 $vo@500$ 是两条独立真值通道；官方场是幅值真值通道（地转 Laplacian 把格点噪声放大约 $6\times$ ：实测 RMS 比 0.164）。在**两条**通道上，在线阶段都挽救了离线闭合并击败自由演变与持续性基线：

5.2 赤字是动力性的，不是谱性的（一个注册的负结果）

为什么更干净的 vo 通道技巧反而更差 (1.348 vs 1.043)? 尺度假设—— vo 含玩具核心表示不了的小尺度内容，过滤真值应能救回技巧——被直接检验（各向同性谱低通，解析参考测试：单模通过/归零、Parseval 账、幂等），并**被实测拒绝**：低通后的真值技巧更差而非更好（在线 1.369 vs 未过滤 1.348），自由演变技巧曲线随截断收紧单调变差。赤字因此不是波长问题。随后的候选—— vo 携带动力流形外（非平衡、惯性重力）内容——也被平衡流形投影审计检验（环 #7）：官方 vo 几乎**就在**平衡流形上（投影 $\approx$ 恒等，能量比 > 0.99 ）——残余误差主要来自玩具核心自身的动力学贫乏，而非真值流形错配。每一步都配守门断言：未来任何对结论的静默改写都会让测试套件转红。**负结果与正结果同等级注册。**

6 物理化雨洪耦合

此前，逐案峰值归一化把每个台风案的降雨峰值钉在同一非维值——抹掉了天鸽 26.7 mm/6h 与苏拉 22.4 mm/6h 不是同一场雨的事实。我们废除了它：ERA5 tp 现在以物理毫米直驱浅水器官（显式映射 $R_{nd} = r_p L_p / (H_p^{3/2} \sqrt{g_p})$ ； L_p 由窗口地理固定， H_p 由标定环锚点**一次**标定、跨案共用）。守门断言编码反归一化不变量：跨案降雨峰值必须按实测毫米排序（天鸽 $>$ 帕卡，峰值比 2.00 vs tp 实测比 2.01）。标定记录连同每案 $\pm 10\%$ 残差一并作为数据发布；绝对深度口径的不确定性显式携带。端到端解析锚定：平地干床均匀物理降雨的水深恰等于 $r_p \times$ 物理已历时（非维-米制往返，相对误差 10^{-6} ）。

对旧参数化桥的十二案对拍量化了桥的空间代理值多少钱：洪峰形态相关 -0.64 至 0.26 （一案反相关），桥域均水深在全部十二案中偏湿 $2.9-15.2\times$ ，损失高估方向同向（弱雨案中 tp 驱动损失接近零时相对差爆至 10^{18} 量级——此时**绝对**误差才是有效读数；被测量的是桥，不是真值）。

7 纪律即方法

五条规则完成了本文的静默工作：（1）实测数字不删除；失败注册进 known-failures 台账，阈值从不放宽求过；（2）每段物理模块配解析参考测试（G2）——手算锚点、Parseval 恒等式、均匀降雨精确解；（3）假设变化时转红的触发线测试升级为真断言，从不删除；（4）部分数据诚实跳过（带修复指引的运行时报错），从不回填；（5）撤回是一等结果——降水台账里就公开展示着一条。我们清楚这种写法在以榜单差值驱动领域里多么反潮流；我们就是要让它成为差异点。

8 局限与诚实边界

玩具核心是 13×13 正压；这里还没有全球引擎。多数基线行用自洽性口径（自身分析场真值）；独立真值验证截至 2026-09-25 已有 $N=4$ 个有效降水对拍 (§4.3)，并随滚动档案持续累积。ENS 对拍待 ECMWF 侧开放。洪水器官的绝对深度带标定区制不确定度。真正的问题——裁判权先于引擎的方法在引擎放大后是否继续兑现——正是下个赛季要测的。

9 工件与滚动更新

- 公开页面（榜单 + 实测基线，滚动）：<https://dolo-borigjin.github.io/The-everything/>
- 仓库（MIT）：<https://github.com/Dolo-borigjin/The-everything>
- Zenodo 归档 release (DOI, concept DOI 始终解析到最新版)：<https://doi.org/10.5281/zenodo.22933596>
- 唯一准绳：leaderboard.json；仲裁：`python -m scalebench.reproduce`（不一致 $> \pm 0.02$ 非零退出）。
- 实测基线经幕等更新器滚动上页（`update_measured.py`，CI 新鲜度校验）；档案清单逐文件 sha256 校验。
- 十二案 ERA5 台风回放（2016-2025，tp 驱动洪水链，物理降雨色标 mm/6h）以交互 demo 随项目工作区发布；其数据管线全程断言守门。

10 下个赛季（滚动）

降水 ETS 样本流的周度累积（首个样本已于 2026-09-24 落地）；ENS 可达后的集合 CRPS；vo 真值通道上的流形原生定律发现；以及您正在读的这份预印本——数字随滚动实测更新。

参考文献

- [1] ECMWF, *AIFS: Artificial Intelligence Forecasting System*, 模式文档与 AIFS blog 系列, 2025–2026.
- [2] Lam, R. et al., *Learning skillful medium-range global weather forecasting* (GraphCast) , Science, 2023.
- [3] Bi, K. et al., *Accurate medium-range global weather forecasting with 3D neural networks* (Pangu-Weather) , Nature, 2023.
- [4] Kochkov, D. et al., *Neural general circulation models for weather and climate*, Nature, 2024.
- [5] Deng, J. et al., *ImageNet: A large-scale hierarchical image database*, CVPR, 2009.

任务族	考题	得分	关键实测
Known-Recovery	known_recovery_kpp	0.998	指数误差 0; Ebert-van Saarloos 渐近外推后系数误差 0.004 (粗割线测量曾为 0.290)
Cross-Resolution	cross_resolution_kpp	1.000	三种网格系数散布 0.000
Long-Horizon	longhorizon_closure_drift	1.000	漂移审计通过; 未标定闭合必然低分
Discovery	spectrum_law_turb2d	1.000	有效谱斜率 -2.03 ± 0.05 ($R^2 = 0.98$) + 双级联; 与渐近 k^{-3} 的 gap 如实上报
Discovery	m3_partition_law	0.976	分配律 $\gamma = 0.7927 \pm 0.0008$ ——发现数据取自守恒审计账
Extrapolation	extrapolation_kpp	0.960	域外 6 配置对拍, 平均相对误差 1.60%
Discovery	nis_prune_consistency	1.000	维度 k 数据驱动; 序参量可重构 (比 0.9991)
Chaos-Audit	chaos_audit_gate	0.994	$\lambda = 0.69295$ vs $\ln 2$ (相对误差 2.9×10^{-4}); 三区制判定全对
Discovery	rg_invariant_sir	0.997	攻击率 ε -collapse 对拍解析最终规模 (偏差 0.34%); 峰高/峰时正确判为非不变量
Long-Horizon	closure_rescue_sir	1.000	在线 SPSSA 目标改进 58.8%; held-out 救援幅度 23.6% (对自由演变); 误差 $2.64 \times$ 神谕上界 (自报)
Extrapolation	extrapolation_turb2d	1.000	ν 加倍 $\times 2$: 斜率 $-2.019 \rightarrow -2.101 \rightarrow -2.265$ 单调变陡 (探针 $R^2 \geq 0.98$); 逐探针偏差上报
Long-Horizon	closure_switch_rescue_sir	0.971	流行中途管控上马: 切换后损失 0.643 vs 冻结 4.820; 反空洞自证通过; 稳定性相对差 9.7×10^{-5}
Long-Horizon	regime_shift_adaptation	1.000	切换族 $t_s=2/3/4$: 门控 RLS 族均改善 38.1%、最差 0.0% (平静期门不开); 无门 RLS 改坏 $t_s=2$ 达 $-1.9 \times$
Discovery	qg2_modal_growth	0.987	斜压急流特征值 $1.12 \times 10^{-5}/s$ @ $m=3$; Benettin/特征值比 0.96; 正压对照稳定; 实场基约定定罪在注
Long-Horizon	decision_tiers_sir	1.000	先知 $0.415 <$ 反应式 $0.627 <$ 部署反馈 0.903 ; 预报价值 0.212 代价单位; 权重 $4 \times$ 切换 MPC 响应
Chaos-Audit	ets_caliber_guard	1.000	三类拒收 (23h/11h/跨年) + 精确窗算术恒等 + 饱和自省
Chaos-Audit	ensemble_bred_qg2	0.845	bred 方向 $0.85 \times$ 模态率; 散布日增 $0.90-0.93 \times$; $s/s=9.4$ 超扩散如实上报 (半分制)
Discovery	rossby_quasi_stationary	1.000	急流 Doppler-RH 漂移 $+6.3 \times 10^{-6}$ vs ERA5 五日准定常 $+4.8 \times 10^{-6}$ rad/s (33%); 地形非锚定在案
总分		0.9864	

表 1: ScaleBench v2.3 榜单 (唯一准绳: `leaderboard.json`)。0.826 是测量伪影而非物理: FD 拉拽前锋滞后归因结果是 pulled front 代数暂态 (非离散误差), 经 Ebert-van Saarloos 渐近估计量 (对数系数带物理签名 $b = -1.5\sqrt{D/r}$) 修正——系数误差 $0.290 \rightarrow 0.004$, 得分 $0.826 \rightarrow 0.998$ (2026-09-25, 事件入测试档案)。其余未满分的题如实记录为物理难度——分数的下限就是物理本身的难度。

时效	z_{500} RMSE 全球 (m^2/s^2)	z_{500} RMSE 珠江口 (m^2/s^2)	MSL RMSE 全球 (Pa)	MSL RMSE 珠江口 (Pa)
+12 h	31.9 [30.2–34.5, $n=4$]	21.1 [4.8–30.4]	73.5 [64.9–80.7]	25.0 [13.5–38.8]
+24 h	46.6 [40.5–50.0, $n=5$]	22.9 [12.4–33.7]	102.9 [95.4–109.3, $n=6$]	26.2 [21.7–31.4]
+48 h	75.3 [69.4–87.7, $n=4$]	18.1 [11.7–24.7]	139.5 [127.2–156.7]	31.9 [25.5–42.1]
+60 h	89.9	18.2	145.0	24.7
+72 h	120.1 [105.6–149.8, $n=4$]	23.2 [17.5–27.9]	179.9 [162.0–203.4]	24.4 [17.3–29.6]
+84 h	129.5	18.4	181.9	26.6
+96 h	176.4 [170.8–181.0, $n=3$]	25.9 [19.7–33.5]	234.3 [222.7–243.2, $n=3$]	44.2 [25.6–59.0]
+120 h	259.2 [253.7–267.1, $n=3$]	41.3 [39.2–43.6]	308.0 [290.0–317.8, $n=3$]	27.4 [16.9–40.7]

表 2: AIFS-single 确定性实测基线（截至 2026-09-25; $n > 1$ 时给多 run 均值与 [min-max, n]）。全球均值随时效单调退化至 120h（ $49 < 72 < 90 < 129 < 150 < 176 < 214 < 259 \text{ m}^2/\text{s}^2$ ，多 run 均值）；窗口级波动是物理的，如实记录。本表在公开页面上滚动更新 (§9)。

真值通道	持续性	自由演变	离线闭合	在线闭合
ζ_g (环 #4)	1.264	1.219	1.313	1.043
vo@500 (环 #5)	1.979	1.948	1.574	1.348
vo@500, 低通 $k \leq 4$ (环 #6)	2.023	2.030	1.603	1.369

表 3: 山竹 2018 窗口 6h 异常技巧 (RMSE/std, 越低越好)。SPSA 在两通道均改进其目标（损失 -31% 与 -20%）。绝对技巧 > 1 如实记录、不设粉饰阈值：登陆窗口演变剧烈，本环考的是训练协议是否 **work**，不是天气预报技巧。