

裁判权先于引擎：天气建模自动重整化的可复现计分牌

LSWM/ARM: ScaleBench 公开基准、AIFS 实时对拍体系，与真实数据训练环的诚实教训

LSWM 项目组

<https://github.com/Dolo-borigjin/The-everything>

<https://dolo-borigjin.github.io/The-everything/>

草稿 v0.5 —— 2026 年 10 月 7 日

(数字为滚动实测并持续更新；更新机制见 §9。)

摘要

天气 AI 目前没有可复现的公开计分牌：头部分数由各团队按自己的数据、标定与真值口径发布，社区无法重算。我们取相反立场——**裁判权先于引擎**：在宣称更好的引擎之前，先建成让此类宣称可被公开检验的仪器。(i) **ScaleBench** (v2.4)：自动重整化公开基准——给定微观模拟器，机器能否自己发现宏观有效定律，并诚实给出适用边界与误差界。五个任务族对应学习有效理论的五种经典失败模式（教科书复读、网格过拟合、短程拟合、插值冒充定律、混沌未审计伪定律）；当前确定性榜单二十题总分 0.9714（截至 2026-10-07，榜单滚动更新——较 0.9864 的下行非回归：第 20 题真值判据经 SPEC-011 批准升级为功率分解口径， $1.000 \rightarrow 0.700$ ，低分如实记录不藏分），由 `reproduce.py` 端到端可执行仲裁（外部提交须全量复现，容差 ± 0.02 ）。(ii) **AIFS 实时对拍体系**：滚动存档（逐文件 sha256 清单）+ 实测基线表（12–120h, z_{500} /MSL RMSE，全球与珠江口窗），真值口径显式标注（自治性 vs 独立再分析），run 间散布作为一等数据记录。(iii) **真实数据训练环**（ERA5 驱动的混合核心 + 穿求解器 SPSA）：在线训练协议在两条独立真值通道上均改进其目标；两通道的绝对技巧差经 **实测拒绝尺度假设**后归因于模型动力流形之外的内容，而非不可分辨的波长。(iv) **雨洪链物理化**：ERA5 总降水以物理毫米直驱浅水洪水器官，一次跨案标定，废除逐案归一化。全程一条铁律：每个数字都是实测、每次失败都注册（含我们自身的一次撤回）、每条物理断言都配解析参考测试。基准、榜单 JSON、复现脚本与滚动实测表全部公开。

1 引言：天气 AI 没有计分牌

业务化 AI 天气模型在聚合技巧指标上已可与传统数值预报比肩 [1, 2, 3]。但证据由各家私有口径产出：验证时段不同、真值流不同（自身分析场 vs ERA5 vs 站点观测）、区域加权不同，且不存在任何公开机制可以重算一个已发表的数字。这与 ImageNet 之前的计算机视觉、GLUE 之前的 NLP 如出一辙——而当时起效的药方不是更好的模型，而是 **更好的尺子**。

其下还压着一个更深的缺口。学习型天气模型的宏大承诺是隐式 **重整化**：从可分辨尺度的动力学中推断次格尺度的有效方程。但“学到了次格物理”是一句不可证伪的口号，除非能**考试**这个

被学出来的有效理论：在答案已知处它能否恢复已知定律？在一百倍训练视界外它是否稳定？它外推，还是只会内插？它知不知道自己何时不知道？

本文就是这两个缺口的计分牌，以及按它打分的第一个实测赛季。贡献：

1. **ScaleBench v2.4** (§3)：防刷分的自动重整化公开基准，配可执行仲裁脚本；确定性管线二十题总分 0.9714。
2. **AIFS 实时对拍体系** (§4)：字节级溯源滚动档案、12-120h 实测确定性基线（真值口径显式标注）、降水 ETS 通道（首个**有效**独立真值样本 2026-09-24 落地，0.1mm 阈值 ETS 0.712）；ENS 端点已探测并如实报告开放商店无货。
3. **真实数据训练环** (§5)：ERA5 驱动的在线训练在两条真值通道上均成立；较干净通道上的技巧赤字经注册的负结果诊断为动力性的，而非谱性的，并以平衡流形投影审计收口。
4. **物理化雨洪耦合** (§6)：ERA5 tp 以物理毫米直驱洪水器官，一次跨案标定；逐案归一化废除并以守门断言防回退。
5. **纪律即方法** (§7)：全部物理代码配解析参考测试、失败注册而非放宽阈值、我们自己的一条错配实测公开撤回。

2 ARM 架构一页

自动重整化机（ARM）是三循环引擎。**内环**学习模拟器次格倾向的闭合；**中环**学习粗粒化映射（哪些宏观变量存在）；**外环**发现有效定律并以 **ETC 卡**（有效理论卡）发出——卡携带误差界、适用区制与标定记录。两道门约束三循环：G1（spec 冻结权属人类）与 G2（每段物理代码配解析参考测试）。**天气器官**把正压玩具核心耦合到在线训练的修正项（穿求解器 SPSA）；**洪水器官**（Lax-Friedrichs 浅水）把降雨接到淹没与损失。架构本身不是本文主题——**对它的考试**才是。完整设计见项目白皮书 (§4 ARM 架构设计)。

3 ScaleBench：自动重整化基准

3.1 设计：五族考题，五种失败模式

每个任务族针对学习有效理论的一种经典翻车方式，每题的防刷分机制公开：

- **Known-Recovery**——恢复已知定律（KPP 行波速度律 $c = 2\sqrt{rD}$ ），评分扣到系数级：有限差分的前锋系统性滞后按实测计入，“看起来对”不得分。
- **Cross-Resolution**——同一定律必须在三种网格下恢复出同一系数；过拟合网格的“定律”在此必现形。
- **Long-Horizon**——闭合在一百倍训练视界上做漂移审计；未标定闭合在此题必然低分。

- **Discovery**——无教科书答案：系统必须输出带误差界与区制边界的宏观方程（含显式 `theory_gap` 字段），由留出数据（held-out）仲裁。
- **Extrapolation**——校准域之外对拍：插值系统域内满分、域外崩溃。这是”定律 vs 插值”的分水岭。
- **Chaos-Audit**——Lyapunov 指数与吸引子距离进验收门：混沌约束必须是实测，不是假设，否则卡不得进入 decision 级。

3.2 榜单（v2.4，确定性管线，种子固定）

3.3 防刷分是实测出来的，不是宣称出来的

湍流谱发现题最初设为”恢复教科书 k^{-3} ”，实测推翻了考题设计本身（四个区制全部测得 -2.0 至 -2.2 ）——考题被修正为区制有效区间，整个事件记录在考题元数据里。计分牌允许自己错，并把改正公开展示。

3.4 可执行仲裁

`python -m scalebench.reproduce` 全量复跑确定性管线，逐题与公开榜单比对（容差 ± 0.02 ，留给跨平台浮点差），任何不一致非零退出。复现全绿是外部提交的前置条件；宣称的误差界覆盖率按二项 z 检验核验；Discovery 族为最终仲裁题。裁判仪器自身也可被裁判。

4 AIFS 实时对拍体系

4.1 字节级溯源的滚动档案

ECMWF 开放数据的 AIFS 馈送是滚动窗口（实测覆盖约 4 天——纠正了最初”约 30 天”的估计）。因此我们业务化存档：自 2026-09-17 起连续捕获每日两个 run 的关键步（0、12、24、48、72、96、120 h 七档），每文件登记 sha256 与字节数；清单校验器可检出篡改、删除与未登记新增。下文任何结论都可回查到它计算时所用的确切字节。

4.2 实测确定性基线（滚动）

真值口径，明说：验证参考是 AIFS 自身后一日 0h 场——自洽性口径（预报与自身分析帧的一致性），不是独立观测的绝对精度。run 间散布作为一等数据记录（单 run 读数不作判决）。

4.3 降水 ETS 通道：两次定罪，然后首个样本落地

首个独立真值对拍（AIFS 24h 累计降水 vs ERA5 日累计，珠江口窗，多阈值 ETS）于 2026-09-24 落地（run 2026-09-18 00z，对拍 2026-09-18 日累计）：AIFS 窗均值 0.34 mm vs ERA5 0.38 mm；多阈值 $ETS = 0.712$ （0.1 mm）、0.241（1 mm）、1.0（5 mm 与 10 mm——小雨事件，高阈值平凡




图 1: AIFS 确定性 z_{500} 全球 RMSE 随时效 (实测, $N=333$ 对, 时效至 240h, 截至 2026-10-07; 均值线 + min-max 散布带)。多样本时效退化单调; 长时效散布按区制成结构 (120h 区制周双簇, 见表 2 caption) ——本身即一等数据。

饱和, 如实标注)。09-25 再落地两个样本 (run 2026-09-18 12z 与 2026-09-19 00z, 对拍 2026-09-19 日累计): 0.1mm 阈值 ETS = 0.830 / 0.495、1mm = 0.176 / 0.143。09-26 第四样本落地 (run 2026-09-20 00z 对拍 2026-09-20 日累计——首个真实雨带案, 窗均值 1.87 vs 1.61 mm): ETS = 0.691 (0.1 mm)、0.609 (1 mm)、0.221 (5 mm——高阈值首次非平凡)、1.0 (10 mm)。

饱和阈值定罪。 第五样本 (按落地顺序, run 日池第四; 2026-09-21, 首个强降雨案: AIFS 2.88 vs ERA5 2.60 mm) 在 0.1mm 阈值 ETS = 0——不是漏报: AIFS 在窗口每个格点都报雨, 观测事件全部「命中」但随机参照恰好等于命中数 (超出随机的技巧为零); 同一对在 1mm 阈值 0.642。多阈值设计自诊断: 饱和在表里可见, 不被头条数字掩盖。

首次判决 (2026-09-28) 及其滚动。 run 日池达 $N=5$ (0.712/0.691/0.495/0.088/0.000) 时, DRAFT-008 首次试算判决落在边界上——**V-INCONCLUSIVE**: 中位 0.495, 距 V-PASS 阈仅 0.005。第六样本 (run 2026-09-23 00z, ETS 0.287) 将池滚至 $N=6$, 中位移至 0.391 (50% 样本 ≥ 0.3 ; 33.3% < 0.2) ——仍为 **V-INCONCLUSIVE**, 但不再是边界案。64 小时停机空白期 (09-30 至 10-02, 在案) 后三样本一次性落地 (09-24: 0.426; 09-25: 0.375; 09-26: 0.172) —— $N=9$, 中位 0.375, 仍 **V-INCONCLUSIVE**, 池向中档收敛而非任一端; 覆盖率判据现已 11/11 全案可分、零假阳。同日 (2026-10-02) 逐时精确窗池达法定样本量 ($n=9$) 并落下 P2 首判——**V-INCONCLUSIVE**, 中位 0.438 (7/9 ≥ 0.3) ——系统性健康于 P1 的 0.375, 与分钟级对齐口径损失更小的预期同向, 两口径同判不翻转。标准启用第一周即产出边界案并由新数据消解——这正是判别力与滚动性的本意。两个裁决议题仍在桌上 (G1-8: 雨日/干日分层; G1-9: 中位数对话

义不同零点的稳健性)。

第三起定罪：时间轴口径。 09-26 通道钓出自家口径错误：ERA5 日文件为**累计结束**口径 (day- d [$d-1$ 23:00, d 23:00))，00z+24h 预报窗只对齐 **run 日文件** ($\pm 1h$)；看似合法的「有效日配对」实为 23h 偏移。一条此类记录 (ETS 0.238，曾被记为真漏雨案) 经逐时精确窗重建定罪 (ETS 0.501，与 run 日配对 0.495 一致)，作为 RETRACTED 证据保留；两处守门已在代码层拒收此类配对，12z run 一律走分钟级逐时精确窗重建 (首个样本 0.840)。有效样本现为双口径合计 (P1 池 $n=14$ ，P2 池 $n=14$ ；判决生效在 §4.3) (run 日 $\pm 1h$ ：0.712/0.495/0.691；精确窗：0.840)；判决标准已于 **2026-10-07 批准冻结** (SPEC-008 v1.0——DRAFT 时代终结；registry 基线 precip_ets_24h 同日由 CLAIMED 翻 MEASURED)。在样本落地之前，管线已钓出两个真实缺陷，均已配守门测试：(i) **千倍单位污染**——AIFS GRIB 的 **tp** 原生单位是 kg m^{-2} (=mm)，而 ERA5 NetCDF 的 **tp** 是米；两条读取路径现在统一经过显式单位归一，遇未知单位直接报错而非静默假设；(ii) 我们自己的**一次跨年份错配** (把 2026 年的预报对拍 2018 年的台风日) ——产生一个貌似合理却毫无意义的“**AIFS 漏掉雨带**”结果。该记录已在公开 JSON 中标记 RETRACTED (证据保留)，对拍 runner 现在硬性拒绝预报窗外的验证日。我们把撤回视为方法的一部分，并把收据留在原地。

4.4 准定常行星波：功率分解，而非相位漂移

方法定罪 (2026-09-29) 与批准 (2026-10-07)。 本节证据最初用日频端点相位差测量。四环定罪链 (全部有锚测试) 废止了该方法：(i) 日频采样单步相位变 $0.97-0.99\pi$ ——快分量混叠回零 (合成锚：快波误测 89%)；(ii) 大步进非低振幅相位噪声——高振幅纬度 churn $0.85-1.58 \text{ rad/日}$ ；(iii) 6 小时真值单步仍 $\approx \pi$ ，与采样率无关——驻波分量使系数相位 $0 \leftrightarrow \pi$ 跳变而无传播。单纬度相位法 (端点与追踪) 在真场上方法论失效；可辩护观测量是时-空功率分解——SPEC-011 于 2026-10-07 批准，使其成为本题正式真值口径。

分解。 准定常不是「漂移小」而是「功率停在 $\omega=0$ 」： $f_0 = P(\omega=0)/\sum P$ (逐纬度 $a_m(t)$ 时间谱零频功率占比， $30-60^\circ\text{N}$ 振幅加权，5 日窗 2026-09-16→20，6 小时间隔)。ERA5 实测 $f_0 = 0.48/0.35/0.19/0.21/0.13$ ($m=3/4/5/6/8$) —— $m=3$ 准定常分量真实 (半数方差五日不动，南半球 0.40)， $m \geq 5$ 瞬态主导并以急流平流速度东进。窗长依赖自身实测： $f_0(m=3) = 2$ 日窗 $0.69 \rightarrow 5$ 日窗 0.48。

模型对照，以及一个诚实的低分。 两层 QG 模型在无任何地形项时产出强定常 $m=3$ 分量 ($f_0 = 0.900$ ，题目同款 2 日积分；真值同窗 $0.69 [0.64-0.77]$)。模型比真值更定常——玩具急流没有天气尺度 churn 浴——差距方向本身就是物理陈述：准定常是急流平衡 (Doppler-Rossby) 现象；理想大陆地形不进一步锚定 (10^{-3} 加速漂移、 10^{-2} 失稳，在案)。批准判据要求真值过 **双窗** (窗稳健性，SPEC-011 选项)；在 2026-09-21 至 25 区制周窗 $f_0(m=8) = 0.259$ 超出 0.25 瞬态带——本题真值判据当前 **未过**，rossby_quasi_stationary 记 0.700 而非 1.000 (低分如实记录不藏分；总分 $0.9864 \rightarrow 0.9714$)。区制周的预报误差超量对我们现有的全部行星波可观测不可见 (振幅/定常

度/传播速度/区域份额/单轨迹 λ /集合散布——六通道六零，后两条为预注册实验判定）；成因如实搁置为开放问题。

4.5 ENS 状态

对 AIFS-ENS 的 CRPS 指标已登记未测：开放商店五种候选集合产品 URL 模式全部 404（2026-09-21 探测，限流退避已遵守），同日确定性产品 206 正常。集合验证需 ECMWF 账号（MARS）或等待官方开放。

5 真实数据训练环：协议成立，赤字是动力性的




图 2: 同化守护重校准提案的结构化残差证据：自由演变对 ERA5 真值的 lag-1 自相关（地转涡度通道，十二台风案全矩阵——8/12 超白噪声门限；未超四案浅色如实保留不隐藏）。2026-09-29 实测；提案仅记账不执行。

天气器官的真实数据链（环 #4-#7）：以 ERA5 派生的涡度真值序列的倾向残差训练点态修正项，再穿求解器做 SPSA 在线微调（多步 rollout 损失）。 13×13 正压核心、6h 步长、异常归一单位。

5.1 协议在两条真值通道上均改进其目标

z_{500} 地转涡度 (ζ_g) 与官方 ERA5 涡度 vo@500 是两条独立真值通道；官方场是幅值真值通道（地转 Laplacian 把格点噪声放大约 $6\times$ ：实测 RMS 比 0.164）。在两条通道上，在线阶段都挽救了离线闭合并击败自由演变与持续性基线：

5.2 赤字是动力性的，不是谱性的（一个注册的负结果）

为什么更干净的 v_o 通道技巧反而更差 (1.348 vs 1.043)? 尺度假设—— v_o 含玩具核心表示不了的小尺度内容，过滤真值应能救回技巧——被直接检验（各向同性谱低通，解析参考测试：单模通过/归零、Parseval 账、幂等），并被**实测拒绝**：低通后的真值技巧更差而非更好（在线 1.369 vs 未过滤 1.348），自由演变技巧曲线随截断收紧单调变差。赤字因此不是波长问题。随后的候选—— v_o 携带动力流形外（非平衡、惯性重力）内容——也被平衡流形投影审计检验（环 #7）：官方 v_o 几乎**就在平衡流形上**（投影 $\approx$ 恒等，能量比 > 0.99 ）——残余误差主要来自玩具核心自身的动力学贫乏，而非真值流形错配。每一步都配守门断言：未来任何对结论的静默改写都会让测试套件转红。负结果与正结果同等级注册。

6 物理化雨洪耦合




图 3: 浅水器官的出流滞后（Ritter 解析对拍的同一求解器）：1.0 非维时间局域降雨停止后，出流率 $t \approx 4.1$ 才到峰、80% 泄放需 $t \approx 9.7$ ——泄放时间尺度比雨期长一个量级，水量演化的主导项是堆积-泄放而非数值泄漏（2026-09-27 实测）。

此前，逐案峰值归一化把每个台风案的降雨峰值钉在同一非维值——抹掉了天鸽 26.7 mm/6h 与苏拉 22.4 mm/6h 不是同一场雨的事实。我们废除了它：ERA5 t_p 现在以物理毫米直驱浅水器官（显式映射 $R_{nd} = r_p L_p / (H_p^{3/2} \sqrt{g_p})$ ； L_p 由窗口地理固定， H_p 由标定环锚点一次标定、跨案共用）。守门断言编码反归一化不变量：跨案降雨峰值必须按实测毫米排序（天鸽 $>$ 帕卡，峰值比 2.00 vs t_p 实测比 2.01）。标定记录连同每案 $\pm 10\%$ 残差一并作为数据发布；绝对深度口径的不确定性显式携带。端到端解析锚定：平地干床均匀物理降雨的水深恰等于 $r_p \times$ 物理已历时（非维-米制往返，相对误差 10^{-6} ）。

对旧参数化桥的十二案对拍量化了桥的空间代理值多少钱：洪峰形态相关 -0.64 至 0.26 （一案反相关），桥域均水深在全部十二案中偏湿 $2.9\text{--}15.2\times$ ，损失高估方向同向（弱雨案中 tp 驱动损失接近零时相对差爆至 10^{18} 量级——此时**绝对**误差才是有效读数；被测量的是桥，不是真值）。

7 纪律即方法

五条规则完成了本文的静默工作：（1）实测数字不删除；失败注册进 known-failures 台账，阈值从不放宽求过；（2）每段物理模块配解析参考测试（G2）——手算锚点、Parseval 恒等式、均匀降雨精确解；（3）假设变化时转红的触发线测试升级为真断言，从不删除；（4）部分数据诚实跳过（带修复指引的运行时报错），从不回填；（5）撤回是一等结果——降水台账里就公开展示着一条。我们清楚这种写法在以榜单差值驱动领域里多么反潮流；我们就是要让它成为差异点。

8 局限与诚实边界

玩具核心是 13×13 正压；这里还没有全球引擎。多数基线行用自洽性口径（自身分析场真值）；独立真值验证截至 2026-10-02 已有二十八个有效降水对拍（P1 $n=14$ 、P2 $n=14$ ，§4.3），并随滚动档案持续累积。ENS 对拍待 ECMWF 侧开放。洪水器官的绝对深度带标定区制不确定度。真正的问题——裁判权先于引擎的方法在引擎放大后是否继续兑现——正是下个赛季要测的。

9 工件与滚动更新

- 公开页面（榜单 + 实测基线，滚动）：<https://dolo-borigjin.github.io/The-everything/>
- 仓库（MIT）：<https://github.com/Dolo-borigjin/The-everything>
- Zenodo 归档 release（DOI，concept DOI 始终解析到最新版）：<https://doi.org/10.5281/zenodo.22933596>
- 唯一准绳：leaderboard.json；仲裁：python -m scalebench.reproduce（不一致 $> \pm 0.02$ 非零退出）。
- 实测基线经幂等更新器滚动上页（update_measured.py，CI 新鲜度校验）；档案清单逐文件 sha256 校验。
- 十二案 ERA5 台风回放（2016–2025，tp 驱动洪水链，物理降雨色标 mm/6h）以交互 demo 随项目工作区发布；其数据管线全程断言守门。
- 本文全部图表由台账经脚本再生（preprint/make_fig_degradation.py、make_fig_outflow_lag.py、make_fig_daemon_residual.py、make_table_baselines.py）——无手抄数字；生成器丢失守门测试即红。

- USD 帧库（z500 十二案 + 水深十二案，各 24 帧，USDA ascii + 自包含预览，preview 与 USDA 逐帧一致有钉测试）随工作区发布，供下游渲染器（Blender/Omniverse）。

10 下个赛季（滚动）

降水 ETS 样本流的周度累积（首个样本已于 2026-09-24 落地）；ENS 可达后的集合 CRPS；vo 真值通道上的流形原生定律发现；以及您正在读的这份预印本——数字随滚动实测更新。

参考文献

- [1] ECMWF, *AIFS: Artificial Intelligence Forecasting System*, 模式文档与 AIFS blog 系列, 2025–2026.
- [2] Lam, R. et al., *Learning skillful medium-range global weather forecasting* (GraphCast), Science, 2023.
- [3] Bi, K. et al., *Accurate medium-range global weather forecasting with 3D neural networks* (Pangu-Weather), Nature, 2023.
- [4] Kochkov, D. et al., *Neural general circulation models for weather and climate*, Nature, 2024.
- [5] Deng, J. et al., *ImageNet: A large-scale hierarchical image database*, CVPR, 2009.

任务族	考题	得分	关键实测
Known-Recovery	known_recovery_kpp	0.998	指数误差 0; Ebert-van Saarloos 渐近外推后系数误差 0.004 (粗割线测量曾为 0.290)
Cross-Resolution	cross_resolution_kpp	1.000	三种网格系数散布 0.000
Long-Horizon	longhorizon_closure_drift	1.000	漂移审计通过; 未标定闭合必然低分
Discovery	spectrum_low_turb2d	1.000	有效谱斜率 -2.03 ± 0.05 ($R^2 = 0.98$) + 双级联; 与渐近 k^{-3} 的 gap 如实上报
Discovery	m3_partition_low	0.976	分配律 $\gamma = 0.7927 \pm 0.0008$ ——发现数据取自守恒审计账
Extrapolation	extrapolation_kpp	0.960	域外 6 配置对拍, 平均相对误差 1.60%
Discovery	nis_prune_consistency	1.000	维度 k 数据驱动; 序参量可重构 (比 0.9991)
Chaos-Audit	chaos_audit_gate	0.994	$\lambda = 0.69295$ vs $\ln 2$ (相对误差 2.9×10^{-4}); 三区制判定全对
Discovery	rg_invariant_sir	0.997	攻击率 ε -collapse 对拍解析最终规模 (偏差 0.34%); 峰高/峰时正确判为非不变量
Long-Horizon	closure_rescue_sir	1.000	在线 SPSS 目标改进 58.8%; held-out 救援幅度 23.6% (对自由演变); 误差 $2.64 \times$ 神谕上界 (自报)
Extrapolation	extrapolation_turb2d	1.000	ν 加倍 $\times 2$: 斜率 $-2.019 \rightarrow -2.101 \rightarrow -2.265$ 单调变陡 (探针 $R^2 \geq 0.98$); 逐探针偏差上报
Long-Horizon	closure_switch_rescue_sir	0.971	流行中途管控上马: 切换后损失 0.643 vs 冻结 4.820; 反空洞自证通过; 稳定性相对差 9.7×10^{-5}
Long-Horizon	regime_shift_adaptation	1.000	切换族 $t_s=2/3/4$: 门控 RLS 族均改善 38.1%、最差 0.0% (平静期门不开); 无门 RLS 改坏 $t_s=2$ 达 $-1.9 \times$
Discovery	qg2_modal_growth	0.987	斜压急流特征值 $1.12 \times 10^{-5}/s$ @ $m=3$; Benettin/特征值比 0.96; 正压对照稳定; 实场基约定定罪在注
Long-Horizon	decision_tiers_sir	1.000	先知 0.415 < 反应式 0.627 < 部署反馈 0.903; 预报价值 0.212 代价单位; 权重 $4 \times$ 切换 MPC 响应
Chaos-Audit	ets_caliber_guard	1.000	三类拒收 (23h/11h/跨年) + 精确窗算术恒等 + 饱和自省
Chaos-Audit	ensemble_bred_qg2	0.845	bred 方向 $0.85 \times$ 模态率; 散布日增 $0.90-0.93 \times$; $s/s=9.4$ 超扩散如实上报 (半分制)
Discovery	rossby_quasi_stationary	0.700	口径升级 (SPEC-011 2026-10-07 批准): 模型 $f_0=0.900$ vs 真值双窗 f_0 分解——真值判据在区制周窗按设计未过 (窗稳健性即判据本意); 低分如实
总分		0.9714	

表 1: ScaleBench v2.4 榜单 (唯一准绳: `leaderboard.json`)。0.826 是测量伪影而非物理: FD 拉拽前锋滞后归因结果是 pulled front 代数暂态 (非离散误差), 经 Ebert-van Saarloos 渐近估计量 (对数系数带物理签名 $b = -1.5\sqrt{D/r}$) 修正——系数误差 $0.290 \rightarrow 0.004$, 得分 $0.826 \rightarrow 0.998$ (2026-09-25, 事件入测试档案)。其余未满分的题如实记录为物理难度——分数的下限就是物理本身的难度。

时效	z_{500} RMSE 全球 (m^2/s^2)	z_{500} RMSE 珠江口 (m^2/s^2)	MSL RMSE 全球 (Pa)	MSL RMSE 珠江口 (Pa)
+12 h	32.0 [28.3–36.3, $n=40$]	16.0 [4.8–48.7, $n=40$]	65.4 [49.9–83.8, $n=40$]	26.2 [8.7–65.0, $n=40$]
+24 h	46.7 [40.5–56.3, $n=43$]	23.0 [5.9–137.2, $n=43$]	86.6 [67.5–109.3, $n=44$]	33.6 [11.2–190.6, $n=44$]
+48 h	87.3 [69.4–115.2, $n=41$]	27.2 [8.2–134.3, $n=41$]	126.8 [103.2–161.8, $n=41$]	40.1 [9.6–135.4, $n=41$]
+60 h	89.9	18.2	145.0	24.7
+72 h	144.7 [105.6–221.3, $n=43$]	54.8 [8.6–436.4, $n=43$]	179.6 [141.2–255.5, $n=43$]	69.4 [14.0–555.4, $n=43$]
+84 h	129.5	18.4	181.9	26.6
+96 h	218.7 [169.8–282.1, $n=37$]	51.5 [10.5–373.7, $n=37$]	256.0 [196.4–306.0, $n=37$]	64.9 [11.8–449.4, $n=37$]
+108 h	214.4	24.7	268.1	52.2
+120 h	327.7 [253.7–418.5, $n=34$]	69.8 [17.9–458.1, $n=34$]	371.9 [279.7–463.5, $n=34$]	82.2 [13.5–649.7, $n=34$]

表 2: AIFS-single 确定性实测基线（截至 2026-10-07，含 2025 台风季回填； $n > 1$ 时给多 run 均值与 [min–max, n]）。多样本时效（ $n \geq 3$ ）的均值口径退化单调；稀疏时效（60/84/108h, $n = 1$ ）可局部破单调，按单 run 读数呈现而非趋势。120h 带（253.7–418.5, $n=34$ ）按区制成双簇：低可预报性区制周（2026-09-21 至 27，均值 359）vs 回落簇（均值 302, [278, 312]）——区制周成因开放（六通道否证链，§4.4）。本表在公开页面上滚动更新（§9）。

真值通道	持续性	自由演变	离线闭合	在线闭合
ζ_g (环 #4)	1.264	1.219	1.313	1.043
vo@500 (环 #5)	1.979	1.948	1.574	1.348
vo@500, 低通 $k \leq 4$ (环 #6)	2.023	2.030	1.603	1.369

表 3: 山竹 2018 窗口 6h 异常技巧 (RMSE/std, 越低越好)。SPSA 在两通道均改进其目标（损失 –31% 与 –20%）。绝对技巧 > 1 如实记录、不设粉饰阈值：登陆窗口演变剧烈，本环考的是训练协议是否 work，不是天气预报技巧。